

Clasificación Multilingüe de Intenciones de Atención al Cliente sobre WhatsApp: Construcción de un Corpus Sintético Multi-Vertical y Comparación de Modelos Clásicos de Aprendizaje Automático frente a Baselines de Reglas y LLM

Rodrigo Vásquez de Velasco

Resumen—Las plataformas de atención al cliente sobre WhatsApp atienden negocios de verticales muy distintas —restaurantes, hoteles, aerolíneas, farmacias, clínicas, bancos, asesorías contables— pero comparten un núcleo común de intenciones que el agente debe identificar antes de derivar la conversación. La práctica actual delega esta clasificación a modelos de lenguaje de gran escala (LLM), incurriendo en latencia y costo aun para mensajes triviales como un saludo o una despedida. Este proyecto investiga si modelos clásicos de aprendizaje automático pueden cubrir esa etapa con calidad equivalente y costo despreciable. Como las plataformas comerciales no liberan sus corpus, construimos un conjunto sintético multilingüe (español, inglés y portugués) de 1320 mensajes balanceados sobre doce intenciones canónicas: constitución de empresas, pedido de comida, reserva de hotel, compra de vuelos, consulta de medicinas, agenda de citas médicas, banca personal, soporte técnico, reclamos, seguimiento de pedidos, saludos y despedidas. La generación combina plantillas con *slot-filling* y ruido superficial (faltas de tildes, abreviaciones, emojis), siguiendo la metodología de Snips y CLINC150. Comparamos Naive Bayes multinomial, K -Nearest Neighbors, Máquinas de Soporte Vectorial, Árboles de Decisión, Bosques Aleatorios y un Perceptrón Multicapa contra dos baselines: un clasificador de expresiones regulares y un LLM en régimen *few-shot*. Reporto F1-macro, matrices de confusión por idioma, latencia y costo de inferencia, y caracterizo el punto de operación en que un sistema híbrido (clasificador clásico + LLM solo para ambigüedades) optimiza el compromiso entre exactitud y costo.

Index Terms—Clasificación de texto, detección de intención, aprendizaje automático supervisado, sistemas de diálogo, procesamiento de lenguaje natural multilingüe, WhatsApp.

I. INTRODUCCIÓN

LOS agentes conversacionales sobre canales de mensajería —particularmente WhatsApp— se han convertido en una interfaz crítica para la atención al cliente y la automatización de flujos comerciales en pequeñas y medianas empresas latinoamericanas [1], [2]. Una etapa central de estos sistemas es la *detección de intención* (*intent classification*): asignar a cada mensaje entrante una de un conjunto finito de categorías

que dirigen el flujo posterior, como pedir comida, reservar un hotel, comprar un vuelo o reclamar por un pedido no entregado [3], [4].

En la práctica industrial reciente esta etapa suele resolverse llamando a un modelo de lenguaje de gran escala (LLM) como GPT-4 u otros [5]. Esta estrategia ofrece una calidad inicial alta sin requerir datos etiquetados, pero traslada todos los mensajes —incluso los más triviales como un saludo o una despedida de una palabra— al mismo modelo costoso y de alta latencia. En despliegues con miles de mensajes diarios el sobre costo se acumula rápidamente, y la dependencia de un proveedor externo introduce un punto único de falla.

I-A. Planteamiento del problema

Las plataformas de atención al cliente sobre WhatsApp atienden simultáneamente negocios de verticales muy distintas. Una pizzería, una agencia de viajes, una farmacia, una clínica médica y una asesoría contable comparten infraestructura conversacional pero reciben mensajes con vocabulario y estructura muy diferentes. Aun así, sobre el conjunto agregado emerge un núcleo común de intenciones genéricas (saludar, despedirse, reclamar, hacer seguimiento de un pedido) y otro núcleo de intenciones *transaccionales* dependientes de la vertical (reservar habitación, pedir pizza, comprar vuelo). El problema de clasificación resultante es multiclase, multilingüe (español, inglés y portugués), con argot, faltas ortográficas, abreviaciones tipo SMS y *code-switching*, escenario en el que los enfoques basados en reglas son notoriamente frágiles [6].

Las plataformas comerciales de este nicho —como NUO o DisZap— no liberan sus corpus de mensajes, lo que dificulta la investigación reproducible. Por ello una contribución de este trabajo es la construcción de un corpus sintético público y reproducible, generado mediante plantillas con *slot-filling* y ruido superficial controlado, en la línea de Snips [3] y CLINC150 [4].

I-B. Hipótesis

Planteo que un clasificador supervisado entrenado sobre representaciones vectoriales clásicas (TF-IDF sobre n -gramas de palabras y de caracteres) puede igualar o superar al baseline

de reglas y aproximarse al LLM en exactitud, a una fracción de la latencia y el costo de inferencia. La hipótesis se sostiene en evidencia previa donde clasificadores clásicos como SVM [7] y modelos lineales eficientes [8] han demostrado ser competitivos en tareas de clasificación de texto cortas y semánticamente acotadas, especialmente en idiomas con recursos limitados.

I-C. Objetivos

I-C1. Objetivo general: Diseñar, entrenar y evaluar un sistema de detección de intención multilingüe para agentes conversacionales de WhatsApp orientados a pequeñas y medianas empresas latinoamericanas, usando algoritmos clásicos de aprendizaje automático, y compararlo cuantitativamente contra un baseline basado en expresiones regulares y contra un LLM operando en régimen *few-shot*.

I-C2. Objetivos específicos:

1. Construir un corpus sintético multilingüe de mensajes tipo WhatsApp, balanceado sobre doce intenciones de alta cobertura comercial, mediante plantillas con *slot-filling* y ruido superficial documentado y reproducible.
2. Implementar y comparar al menos seis modelos cubiertos en el curso: Naive Bayes multinomial, K -Nearest Neighbors, Máquinas de Soporte Vectorial (lineal y RBF), Árboles de Decisión, Bosques Aleatorios y un Perceptrón Multicapa.
3. Reportar F1-macro, exactitud, matrices de confusión por idioma, latencia media y costo monetario estimado por inferencia frente a los dos baselines.
4. Definir un punto de operación de un sistema híbrido que delegue al LLM únicamente los mensajes con baja confianza del clasificador clásico, y cuantificar el ahorro resultante.

I-D. Dataset

Construí un corpus sintético de **1 320 mensajes** balanceados sobre doce intenciones (110 mensajes por clase), con distribución multilingüe aproximada del 70 % en español, 20 % en inglés y 10 % en portugués para reflejar la composición observada en plataformas comerciales del nicho. La taxonomía cubre tres familias:

- *Intenciones transaccionales verticales:*
constituir_empresa, comprar_pizza,
reservar_hotel, comprar_vuelo,
consultar_medicina, agendar_cita_medica,
consulta_banca.
- *Intenciones genéricas de servicio:* soporte_tecnico,
reclamo, seguimiento_pedido.
- *Intenciones conversacionales:* saludo, despedida.

La generación se realiza mediante un *script* Python que combina plantillas específicas por idioma con vocabularios de *slots* (acciones, productos, ciudades, síntomas, especialidades médicas, etc.) y aplica una capa de ruido superficial controlado: conversión a minúsculas, eliminación de tildes, abreviaciones tipo SMS (k por *que*, x por *por*), inserción de emojis y agregado de fragmentos de cortesía. Esta metodología es análoga a la construcción de los corpus de Snips [3] y

CLINC150 [4], e introduce variabilidad realista sin requerir anotadores humanos a gran escala.

El preprocesamiento previo al entrenamiento incluirá normalización Unicode, eliminación de URLs, conservación de emojis como *tokens* discretos y vectorización TF-IDF sobre n -gramas de palabras (1–2) y de caracteres (3–5) [9]. Se reservará un 15 % del corpus como conjunto de prueba, con muestreo estratificado por intención e idioma.

II. REVISIÓN BIBLIOGRÁFICA

II-A. Clasificación de texto con modelos clásicos

La clasificación supervisada de texto es un problema canónico del aprendizaje automático. Joachims [7] demostró tempranamente que las máquinas de soporte vectorial son particularmente adecuadas para este escenario debido a su capacidad de manejar espacios de características de alta dimensionalidad y dispersión, propiedades inherentes a las representaciones *bag-of-words* y TF-IDF. Posteriormente, Joulin *et al.* [8] mostraron que un clasificador lineal entrenado sobre embeddings de palabras promediados —FastText— alcanza desempeños competitivos con redes profundas en tareas de clasificación de oraciones cortas, a varios órdenes de magnitud menos costo computacional. Pang y Lee [6] consolidaron las prácticas de preprocesamiento, ingeniería de características y evaluación que permanecen vigentes en clasificadores ligeros, las cuales adopto en este trabajo.

II-B. Detección de intención en sistemas de diálogo

La detección de intención es el problema de clasificación subyacente en la mayoría de los sistemas conversacionales de dominio cerrado [2]. Coucke *et al.* [3] describen la plataforma Snips, donde un clasificador en dispositivo combina características léxicas y embeddings para alcanzar latencias inferiores a la decena de milisegundos, demostrando que arquitecturas ligeras son viables en producción bajo restricciones estrictas de privacidad y cómputo. Larson *et al.* [4] introdujeron el conjunto CLINC150, que se ha convertido en una referencia estándar para evaluar clasificadores de intención multiclase y especialmente su comportamiento ante mensajes *out-of-scope*, una situación directamente análoga al ambiguo de la taxonomía propuesta.

II-C. Sistemas de diálogo y modelos de lenguaje a gran escala

Chen *et al.* [1] presentan un *survey* de la evolución reciente de los sistemas de diálogo, evidenciando el desplazamiento progresivo desde *pipelines* modulares (NLU $\rightarrow$ DST $\rightarrow$ NLG) hacia arquitecturas *end-to-end*. Brown *et al.* [5] mostraron que LLMs a gran escala son capaces de resolver tareas de clasificación con muy pocos ejemplos (*few-shot*), lo cual motiva su uso actual como *baseline* de calidad pero también evidencia su costo de inferencia y latencia. Esta tensión entre calidad y eficiencia es precisamente el espacio que este proyecto pretende caracterizar empíricamente.

II-D. Representaciones de palabras y herramientas

Las representaciones distribucionales propuestas por Mikolov *et al.* [10] establecieron las bases para que clasificadores clásicos pudieran operar sobre features semánticas densas en lugar de únicamente recuentos léxicos, mejorando significativamente la generalización en escenarios multilingües. Para la implementación emplearé las rutinas estándar de `scikit-learn` [9], que ofrece todos los algoritmos del curso bajo una API uniforme y reproducible.

III. EVALUACIÓN PRELIMINAR DEL BASELINE LLM

Antes de entrenar y comparar los modelos clásicos, caracterizo el rendimiento del baseline basado en LLM contra el cual mediré las arquitecturas livianas propuestas. Este último establece el techo de calidad esperado y permite contrastar costo y latencia con el desempeño de Naive Bayes, KNN, SVM, árboles de decisión, bosques aleatorios y MLP en las secciones siguientes.

III-A. Configuración experimental

El baseline LLM emplea `openai/gpt-4o-mini` accedido a través de la API agregadora OpenRouter, con `temperature=0,2` y límite de 600 tokens de salida. La instrucción de sistema explicita las doce intenciones canónicas y solicita una salida estructurada con etiqueta, idioma, confianza, razonamiento y recomendación de modelo. Para enriquecer el contexto se incorpora un sistema de recuperación aumentada (RAG) que indexa el corpus completo bajo embeddings `text-embedding-3-large` de 1536 dimensiones almacenados en una base `pgvector`; en cada inferencia se recuperan los 8 fragmentos más similares por similitud coseno mediante un índice `ivfflat`. El servicio se despliega en un microservicio dedicado, con autenticación por token interno entre micros.

III-B. Resultados sobre el corpus completo

Evalúo el baseline sobre la totalidad del corpus generado ($N = 1320$ mensajes), con muestreo estratificado por (intención $\times$ idioma). El sistema alcanza una exactitud global de 0,9705 y un F1-macro de 0,9728, con 39 predicciones erróneas (2,95 %). El desempeño por idioma se resume en la Tabla I y el comportamiento por clase en la Tabla II. La matriz de confusión completa, normalizada por clase verdadera, se muestra en la Figura 1.

Tabla I
DESEMPEÑO DEL BASELINE LLM POR IDIOMA SOBRE EL CORPUS COMPLETO ($N = 1320$).

Idioma	N	Aciertos	Accuracy	F1 macro
Español (ES)	906	880	0,9713	0,9718
Inglés (EN)	288	275	0,9549	0,9621
Portugués (PT)	126	126	1,0000	1,0000
Global	1320	1281	0,9705	0,9728

III-C. Análisis de errores

Las 39 predicciones incorrectas observadas se concentran en cuatro patrones cualitativos:

Tabla II
PRECISIÓN, RECALL Y F1 POR INTENCIÓN CANÓNICA ($N = 1320$, SOPORTE = 110 POR CLASE).

Intención	TP	Precisión	Recall	F1
constituir_empresa	109	1,000	0,991	0,995
comprar_pizza	109	1,000	0,991	0,995
reservar_hotel	110	1,000	1,000	1,000
comprar_vuelo	110	1,000	1,000	1,000
consultar_medicina	110	0,821	1,000	0,902
agendar_cita_medica	88	1,000	0,800	0,889
consulta_banca	96	1,000	0,873	0,932
soporte_tecnico	110	0,940	1,000	0,969
reclamo	110	1,000	1,000	1,000
seguimiento_pedido	110	1,000	1,000	1,000
saludo	110	1,000	1,000	1,000
despedida	110	1,000	1,000	1,000




Figura 1. Matriz de confusión del baseline LLM normalizada por clase verdadera ($N = 1320$). El error sistemático más visible es la transferencia de masa de `agendar_cita_medica` hacia `consultar_medicina`.

III-C0a. Confusión transaccional vs informativa (22/39, 56 %): Veintidós errores en `agendar_cita_medica` fueron clasificados como `consultar_medicina`, típicamente mensajes con vocabulario de especialidad médica como “¿cuánto cuesta una consulta de pediatría?”, “Necesito una consulta de psicología” o “Do you have availability in dentistry?”. El LLM no separa correctamente la intención de *información previa* de la intención *transaccional* cuando ambas comparten vocabulario. Esto sugiere que la señal discriminativa requerida es léxico-sintáctica (verbos modales, formas interrogativas, marcadores temporales) más que semántica, hipótesis verificable con clasificadores clásicos sobre *n*-gramas.

III-C0b. Confusión banca ↔ soporte técnico (14/39, 36 %): Catorce mensajes etiquetados como `consulta_banca` fueron clasificados como `soporte_tecnico` (siete) o como otras categorías (siete). El factor común es la palabra *cuenta*, léxicamente ambigua entre *cuenta bancaria* y *cuenta de aplicación*, ejemplificado por “Mi cuenta no funciona”. Una clasificación robusta requerirá señales adicionales de contexto que las representaciones bag-of-words capturan parcialmente; este es

un caso natural para evaluar el aporte de embeddings densos.

III-C0c. Errores aislados (3/39, 8 %): Tres errores aislados involucraron a `constituir_empresa` (1) y `comprar_pizza` (1) confundidos con clases semánticamente cercanas, más un caso de alucinación léxica donde el LLM produjo el token `consultar_banca` (no canónico) en lugar de `consulta_banca`. Esta última limitación es estructuralmente imposible para los clasificadores supervisados, cuyo espacio de salida está restringido por construcción al conjunto entrenado.

III-C0d. Distribución por idioma: El español concentra la mayoría de los errores (26/39 $\approx 67\%$), reflejando tanto la mayor representación del idioma en el corpus (69 %) como una mayor riqueza léxica que expone los casos límite. El portugués alcanza exactitud perfecta (126/126); aunque el resultado es alentador, debe interpretarse con cautela dado el tamaño muestral y la simplicidad sintáctica del subcorpus PT.

III-D. Implicaciones para el sistema híbrido

Los resultados anteriores tienen tres consecuencias directas para la arquitectura híbrida que este trabajo propone caracterizar:

1. El baseline LLM establece un techo empírico de F1-macro $\approx 0,973$ con latencia media de 3,23 s por inferencia (mín = 1,47 s, máx = 28,70 s); cualquier modelo clásico que se aproxime a esta cifra con latencia < 100 ms y costo despreciable valida operacionalmente la hipótesis del proyecto.
2. Las dos confusiones sistemáticas detectadas (`agendar_cita_medica` $\rightarrow$ `consultar_medicina` y `consulta_banca` $\rightarrow$ `soporte_tecnico`) concentran 36/39 de los errores y representan oportunidades concretas para que un clasificador supervisado las resuelva mediante *features* léxicos explícitos. Si los modelos clásicos igualan al LLM en el resto y mejoran específicamente en estos dos pares, la conclusión del paper es directa.
3. La alucinación de etiquetas y la opacidad de la confianza del LLM justifican el diseño del punto de operación híbrido: el clasificador clásico opera como ancla del espacio de salida y el LLM se invoca únicamente cuando la confianza del clasificador cae bajo un umbral, evitando que las inconsistencias estructurales del LLM contaminen el flujo del agente conversacional.

Esta evaluación establece la línea base contra la cual se reportará el desempeño de los modelos clásicos en la Sección de Resultados (entrega final).

REFERENCIAS

- [1] H. Chen, X. Liu, D. Yin, and J. Tang, "A survey on dialogue systems: Recent advances and new frontiers," *ACM SIGKDD Explorations Newsletter*, vol. 19, no. 2, pp. 25–35, 2017.
- [2] G. Tur and R. De Mori, Eds., *Spoken Language Understanding: Systems for Extracting Semantic Information from Speech*. Hoboken, NJ, USA: John Wiley & Sons, 2011.
- [3] A. Coucke, A. Saade, A. Ball, T. Bluche, A. Caulier, D. Leroy, C. Doumouro, T. Gisselbrecht, F. Caltagirone, T. Lavril, M. Primet, and J. Dureau, "Snips voice platform: An embedded spoken language understanding system for private-by-design voice interfaces," *arXiv preprint arXiv:1805.10190*, 2018.
- [4] S. Larson, A. Mahendran, J. J. Peper, C. Clarke, A. Lee, P. Hill, J. K. Kummerfeld, K. Leach, M. A. Laurenzano, L. Tang, and J. Mars, "An evaluation dataset for intent classification and out-of-scope prediction," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Association for Computational Linguistics, 2019, pp. 1311–1316.
- [5] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell *et al.*, "Language models are few-shot learners," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 1877–1901.
- [6] B. Pang and L. Lee, "Opinion mining and sentiment analysis," in *Foundations and Trends in Information Retrieval*, vol. 2, no. 1–2. Now Publishers Inc., 2008, pp. 1–135.
- [7] T. Joachims, "Text categorization with support vector machines: Learning with many relevant features," in *Proceedings of the 10th European Conference on Machine Learning (ECML)*. Springer-Verlag, 1998, pp. 137–142.
- [8] A. Joulin, E. Grave, P. Bojanowski, and T. Mikolov, "Bag of tricks for efficient text classification," in *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers*. Valencia, Spain: Association for Computational Linguistics, 2017, pp. 427–431.
- [9] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [10] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," *arXiv preprint arXiv:1301.3781*, 2013.