

Clasificación Multilingüe de Intenciones de Atención al Cliente sobre WhatsApp: Modelos Clásicos de Aprendizaje Automático frente a Baselines de Reglas y LLM sobre un Corpus Sintético Multi-Vertical

Rodrigo Vásquez de Velasco

Resumen—Las plataformas de atención al cliente sobre WhatsApp atienden verticales muy distintas pero comparten un núcleo común de intenciones. La práctica actual delega esta clasificación a un LLM, con latencia y costo aun para mensajes triviales. Investigamos si modelos clásicos pueden cubrir esa etapa con calidad equivalente. Ante la ausencia de corpus comerciales públicos, construimos un corpus sintético multilingüe (español, inglés, portugués) de 1320 mensajes sobre doce intenciones, generado con plantillas, *slot-filling* y ruido superficial. Comparamos Naive Bayes, K -NN, SVM, Árboles de Decisión, Bosques Aleatorios y un Perceptrón Multicapa contra un baseline de reglas y contra un baseline LLM. El mejor clasificador clásico alcanza F1-macro de 0,965, frente a 0,973 del LLM, con latencia cuatro órdenes de magnitud menor. Un sistema híbrido que delega al LLM sólo el 3 % de los mensajes iguala su exactitud ahorrando el 97 % de las llamadas.

Index Terms—Clasificación de texto, detección de intención, aprendizaje automático supervisado, sistemas de diálogo, procesamiento de lenguaje natural multilingüe, WhatsApp.

I. INTRODUCCIÓN

LOS agentes conversacionales sobre canales de mensajería, particularmente WhatsApp, se han convertido en una interfaz crítica para la atención al cliente y la automatización de flujos en pequeñas y medianas empresas latinoamericanas [1], [2]. Una etapa central de estos sistemas es la *detección de intención*: asignar a cada mensaje entrante una de un conjunto finito de categorías que dirigen el flujo posterior [3], [4].

En la práctica industrial reciente esta etapa suele resolverse llamando a un LLM como GPT-4 u otros [5]. Esta estrategia ofrece una calidad inicial alta sin requerir datos etiquetados, pero traslada todos los mensajes —incluso los más triviales, como un saludo o una despedida— al mismo modelo costoso y de alta latencia. En despliegues con miles de mensajes diarios el sobrecosto se acumula rápidamente y la dependencia de un proveedor externo introduce un punto único de falla.

I-A. Planteamiento del problema

Una pizzería, una agencia de viajes, una farmacia, una clínica médica y una asesoría contable comparten infraestructura

conversacional pero estructura muy diferente. Aun así, sobre el conjunto agregado emerge un núcleo común de intenciones genéricas (saludar, despedirse, reclamar, hacer seguimiento de un pedido) y otro núcleo de intenciones *transaccionales* dependientes de la vertical (reservar habitación, pedir pizza, comprar vuelo). El problema de clasificación resultante es multiclase, multilingüe (español, inglés y portugués), con argot, faltas ortográficas, abreviaturas tipo SMS y *code-switching*, escenario en el que los enfoques basados en reglas son notoriamente frágiles [6].

I-B. Hipótesis

Planteamos que un clasificador supervisado entrenado sobre representaciones vectoriales clásicas (TF-IDF sobre n -gramas de palabras y caracteres) puede igualar o superar al baseline de reglas y aproximarse al LLM en exactitud, a una fracción de la latencia y el costo de inferencia. La hipótesis se sostiene en evidencia previa donde clasificadores clásicos como SVM [7] y modelos lineales eficientes [8] han demostrado ser competitivos en clasificación de texto corto [9], especialmente en idiomas con recursos acotados.

I-C. Objetivos

Objetivo general: diseñar, entrenar y evaluar un sistema de detección de intención multilingüe para agentes conversacionales de WhatsApp usando algoritmos clásicos, y compararlo cuantitativamente contra un baseline de reglas y contra un LLM en régimen *few-shot*. **Objetivos específicos:** (1) construir un corpus sintético multilingüe reproducible; (2) implementar y comparar los modelos clásicos del curso; (3) reportar F1-macro, exactitud, matrices de confusión por idioma y latencia frente a los dos baselines; y (4) definir el punto de operación de un sistema híbrido que delegue al LLM únicamente los mensajes de baja confianza.

I-D. Dataset

Construimos un corpus sintético de **1320 mensajes** balanceados sobre doce intenciones (110 por clase), con distribución multilingüe aproximada del 70 %

en español, 20 % en inglés y 10 % en portugués. La taxonomía cubre tres familias: intenciones transaccionales verticales (`constituir_empresa`, `comprar_pizza`, `reservar_hotel`, `comprar_vuelo`, `consultar_medicina`, `agendar_cita_medica`, `consulta_banca`), genéricas de servicio (`soporte_tecnico`, `reclamo`, `seguimiento_pedido`) y conversacionales (`saludo`, `despedida`). La generación y su justificación se detallan en la Sección III.

II. REVISIÓN BIBLIOGRÁFICA

II-A. Clasificación de texto con modelos clásicos

La clasificación supervisada de texto es un problema canónico del aprendizaje automático. Joachims [7] demostró tempranamente que las máquinas de soporte vectorial son particularmente adecuadas por su capacidad de manejar espacios de alta dimensionalidad y dispersión, propiedades inherentes a las representaciones *bag-of-words* y TF-IDF. Cortes y Vapnik [10] formalizaron el margen máximo que subyace a estos clasificadores. Posteriormente, Joulin *et al.* [8] mostraron que un clasificador lineal sobre *embeddings* promediados alcanza desempeños competitivos con redes profundas en clasificación de oraciones cortas a mucho menor costo. Breiman [11] introdujo los bosques aleatorios como un ensemble robusto frente al sobreajuste, mientras que la regla del vecino más cercano [12] sigue siendo una línea base no paramétrica útil. Pang y Lee [6] consolidaron prácticas de preprocesamiento e ingeniería de características que permanecen vigentes en clasificadores ligeros.

II-B. Detección de intención en sistemas de diálogo

La detección de intención es el problema de clasificación subyacente en la mayoría de los sistemas conversacionales de dominio cerrado [2]. Coucke *et al.* [4] describen la plataforma Snips, con un clasificador en dispositivo que combina características léxicas y *embeddings* para alcanzar latencias inferiores a la decena de milisegundos, demostrando arquitecturas ligeras viables en producción bajo restricciones de privacidad. Larson *et al.* [3] introducen CLINC150, referencia estándar para evaluar clasificadores de intención multiclase con mensajes *out-of-scope*. Casanueva *et al.* [13] muestran que codificadores de oraciones duales logran detección de intención eficiente con pocos ejemplos, y Zhang *et al.* [14] proponen un enfoque discriminativo por vecino más cercano para el régimen *few-shot*, evidenciando el interés continuo por soluciones de bajo costo de etiquetado.

II-C. Representaciones y modelos de lenguaje

Las representaciones distribucionales de Mikolov *et al.* [15] y Pennington *et al.* [16] sentaron las bases para features semánticos densos. La arquitectura Transformer [17] y modelos preentrenados como BERT [18] y su variante de oraciones [19] redefinieron el estado del arte, aunque a un costo computacional mayor. Brown *et al.* [5] y Ouyang *et al.* [20] mostraron que los LLM resuelven tareas de clasificación con muy pocos ejemplos (*few-shot*), lo cual motiva su uso




Figura 1. Distribución del corpus sintético: 110 mensajes por cada una de las doce intenciones y reparto multilingüe 70/20/10 (ES/EN/PT).

actual como baseline de calidad pero también evidencia su costo de inferencia y latencia. Esta tensión entre calidad y eficiencia es precisamente el espacio que este proyecto caracteriza empíricamente.

II-D. Multilingüismo y datos sintéticos

El carácter multilingüe del problema conecta con trabajos de aprendizaje translingual: Conneau *et al.* [21] presentan XLM-R para representaciones translinguales a escala, y Schuster *et al.* [22] abordan la transferencia entre idiomas en diálogo orientado a tareas. FitzGerald *et al.* [23] publican MASSIVE, un corpus multilingüe masivo de comprensión de lenguaje natural. Ante la ausencia de corpus comerciales públicos, la generación sintética y la aumentación de datos son estrategias establecidas; Wei y Zou [24] muestran que técnicas sencillas de aumentación mejoran la clasificación de texto, lo que respalda metodológicamente la construcción de nuestro corpus con plantillas y ruido controlado. Para toda la implementación se emplean las rutinas estándar de `scikit-learn` [25].

III. METODOLOGÍA

III-A. Construcción del corpus

El corpus se genera con un *script* Python reproducible (semilla fija). Para cada intención e idioma se define un conjunto de plantillas con *slots* (ciudades, síntomas, especialidades médicas, productos, aerolíneas, etc.) rellenos desde vocabularios específicos. Sobre cada mensaje se aplica una capa de **ruido superficial** aleatorio: conversión a minúsculas, eliminación de tildes, abreviaturas tipo SMS (*q* por *que*, *x* por *por*), inserción de emojis, fragmentos de cortesía y tipos de un carácter (*swap*, borrado o duplicado). Esta metodología es análoga a la de Snips [4] y CLINC150 [3] e introduce variabilidad realista sin anotadores humanos.

Un aspecto de diseño clave es la **frontera léxica ambigua**: el 30 % de cada clase proviene de plantillas que comparten superficie con una clase vecina. Así, la frase “mi cuenta no funciona” aparece etiquetada tanto como `consulta_banca` (cuenta bancaria) como `soporte_tecnico` (cuenta de la aplicación), y las preguntas de precio “¿cuánto cuesta una consulta de pediatría?” se solapan entre `agendar_cita_medica` y `consultar_medicina`. Esta ambigüedad reproduce las confusiones reales anticipadas en el informe preliminar y evita una separabilidad artificialmente perfecta. La Fig. 1 resume la distribución resultante.

III-B. Preprocesamiento y representación

El preprocesamiento normaliza Unicode, pasa a minúsculas y elimina URLs, *conservando los emojis* como tokens discriminativos. La representación vectorial combina, mediante FeatureUnion, un TF-IDF de *n-gramas de palabras* (1–2) con un TF-IDF de *n-gramas de caracteres* (3–5). El componente de caracteres aporta robustez frente a faltas ortográficas y abreviaturas, mientras que el de palabras captura la semántica léxica. Se aplica `sublinear_tf` y `min_df=2`. Se reserva un 15 % del corpus como conjunto de prueba con muestreo estratificado por la intersección intención×idioma.

III-C. Modelos implementados y justificación

Se implementan los modelos vistos en el curso, cada uno justificado por su adecuación al problema:

- **Naive Bayes multinomial**: línea base probabilística natural para conteos TF-IDF; fuerte con datos escasos y de alta dimensión.
- **K-NN** (coseno, $k=5$): no paramétrico; útil cuando las clases forman agrupamientos léxicos compactos [12].
- **SVM lineal y RBF**: referencia histórica en clasificación de texto de alta dimensión [7], [10]; el kernel RBF explora fronteras no lineales.
- **Árbol de Decisión**: modelo interpretable, útil como contraste de baja capacidad.
- **Bosques Aleatorios** (300 árboles): ensamble robusto frente al sobreajuste [11].
- **Perceptrón Multicapa (MLP)**: una capa oculta de 256 unidades con parada temprana; introduce no linealidad a bajo costo.

Como órdenes de referencia se incluyen: (i) un **baseline de reglas** determinista basado en expresiones regulares por intención, y (ii) el **baseline LLM** evaluado en el informe preliminar (`gpt-4o-mini` con recuperación aumentada por embeddings), cuyas métricas empíricas se reutilizan aquí como techo de calidad.

III-D. Sistema híbrido

Se caracteriza un sistema híbrido que resuelve con el clasificador clásico los mensajes cuya confianza (probabilidad máxima calibrada) supera un umbral τ , y delega al LLM el resto. Para un rango de umbrales se estima la exactitud del sistema combinando los aciertos del clasificador en los mensajes retenidos con la exactitud empírica del LLM en los delegados, y se selecciona el punto de operación de *menor delegación* que iguala la exactitud del LLM puro.

IV. RESULTADOS

IV-A. Desempeño global

La Tabla I resume el desempeño de todos los sistemas sobre el conjunto de prueba ($N=198$). Los siete modelos clásicos superan ampliamente al baseline de reglas (F1-macro 0,825). El mejor clasificador es **Naive Bayes** (empatado con el MLP) con F1-macro de **0,965** y exactitud 0,965, apenas por debajo del baseline LLM (F1-macro 0,973), pero con una

Cuadro I
DESEMPEÑO GLOBAL SOBRE EL CONJUNTO DE PRUEBA ($N=198$).
LATENCIA DE INFERENCIA POR MENSAJE. EL LLM PROVIENE DEL
INFORME PRELIMINAR.

Sistema	Exactitud	F1-macro	Latencia
Baseline de reglas	0,803	0,825	< 0,01 ms
Árbol de Decisión	0,828	0,827	0,025 ms
K-NN	0,924	0,924	0,045 ms
Bosques Aleatorios	0,934	0,934	0,150 ms
SVM RBF	0,944	0,945	0,275 ms
SVM lineal	0,960	0,960	0,029 ms
Perceptrón (MLP)	0,965	0,965	0,031 ms
Naive Bayes	0,965	0,965	0,025 ms
Baseline LLM [5]	0,971	0,973	3 230 ms




Figura 2. F1-macro por modelo sobre el test. Las líneas discontinuas marcan el baseline de reglas (rojo) y el baseline LLM (verde).




Figura 3. Compromiso entre latencia de inferencia (escala log) y F1-macro. Los modelos clásicos se agrupan en calidad alta con latencia sub-milisegundo, frente a los segundos del LLM.

latencia de inferencia de 0,025 ms por mensaje frente a los 3 230 ms del LLM: una reducción de más de cuatro órdenes de magnitud. La Fig. 2 muestra la comparación visual y la Fig. 3 el compromiso latencia–calidad.

IV-B. Desempeño por idioma

La Tabla II desglosa el desempeño del mejor modelo por idioma. El portugués alcanza exactitud perfecta y el inglés 0,972; el español concentra los errores (0,957), coherente con su mayor representación (70 % del corpus) y mayor riqueza

Cuadro II
DESEMPEÑO DEL MEJOR MODELO (NAIVE BAYES) POR IDIOMA.

Idioma	N	Exactitud	F1-macro
Español (ES)	138	0,957	0,957
Inglés (EN)	36	0,972	0,971
Portugués (PT)	24	1,000	1,000
Global	198	0,965	0,965




Figura 4. Matriz de confusión del mejor modelo (Naive Bayes), normalizada por clase verdadera. El error se concentra en los pares `consultar_medicina/agendar_cita_medica` y `consulta_banca/soporte_tecnico`.

léxica, exactamente el patrón observado en el baseline LLM del informe preliminar.

IV-C. Análisis de errores

La Fig. 4 muestra la matriz de confusión del mejor modelo. Ocho de las doce intenciones se clasifican perfectamente. La totalidad del error se concentra en los dos pares léxicamente ambiguos anticipados en el informe preliminar:

- `consultar_medicina` ↔ `agendar_cita_medica`: el 24 % de los mensajes de consulta médica redactados como preguntas de precio se clasifican como agendamiento de cita (recall 0,765).
- `consulta_banca` ↔ `soporte_tecnico`: el vocablo “cuenta” es léxicamente ambiguo (cuenta bancaria vs. cuenta de la aplicación), generando confusión bidireccional (12 % y 6 %).

Estas confusiones son *irreducibles* por construcción del corpus y reproducen exactamente los patrones que el baseline LLM también exhibió, lo que valida la equivalencia de comportamiento entre ambos enfoques.

IV-D. Sistema híbrido

La Fig. 5 traza la curva costo–exactitud del sistema híbrido. Partiendo del clasificador clásico puro (0,965), delegar al




Figura 5. Compromiso costo–exactitud del sistema híbrido. La exactitud iguala al LLM puro (línea verde) delegando sólo el 3 % de los mensajes, y lo supera con un 6 %.

LLM únicamente los mensajes de baja confianza incrementa la exactitud rápidamente. En su punto de operación —umbral $\tau = 0,90$ — el sistema delega apenas el **3,0 %** de los mensajes y alcanza una exactitud de **0,974**, igualando al LLM puro pero **ahorrando el 97 % de las llamadas** al modelo costoso. Delegando un 6 % se alcanza un máximo de 0,978, superando al LLM puro. La latencia media del sistema híbrido baja de 3,23 s a $\approx 0,10$ s por mensaje, cerca de dos órdenes de magnitud de mejora.

V. CONCLUSIONES

Los resultados confirman la hipótesis del proyecto. Primero, los modelos clásicos superan holgadamente al baseline de reglas (0,965 vs. 0,825 de F1-macro), evidenciando que las representaciones léxicas aprendidas capturan la variabilidad multilingüe y el ruido superficial que las reglas no manejan. Segundo, el mejor clasificador clásico (Naive Bayes, empatado con el MLP) alcanza un F1-macro de 0,965, a sólo 0,008 del baseline LLM, con una latencia cuatro órdenes de magnitud menor y costo de inferencia despreciable; la hipótesis de equivalencia práctica queda validada. Tercero, el error residual del clasificador se concentra exactamente en los dos pares léxicamente ambiguos que también confundieron al LLM, mostrando que ambos enfoques comparten el mismo límite de separabilidad. Finalmente, el sistema híbrido demuestra que delegar al LLM únicamente el 3 % de los mensajes de baja confianza recupera —e incluso supera— la exactitud del LLM puro, ahorrando el 97 % de las llamadas. Para el escenario de PyMEs latinoamericanas sobre WhatsApp, un clasificador clásico con *fallback* selectivo al LLM es la arquitectura de mejor compromiso entre exactitud, latencia y costo.

VI. TRABAJO FUTURO

Se identifican varias líneas de mejora. (1) **Datos reales**: validar los modelos sobre mensajes reales anonimizados de plataformas en producción, más allá del corpus sintético, y medir la brecha de dominio. (2) **Representaciones densas**: sustituir o complementar el TF-IDF con *embeddings* multilingües como XLM-R [21] o Sentence-BERT [19] para atacar específicamente las confusiones semánticas residuales,

mediando el costo adicional. (3) **Detección out-of-scope**: incorporar una categoría de rechazo al estilo de CLINC150 [3] para mensajes fuera de la taxonomía. (4) **Calibración del umbral**: optimizar el umbral de delegación del sistema híbrido mediante validación cruzada y funciones de costo explícitas que ponderen el precio real de cada llamada al LLM. (5) **Ampliación de la taxonomía y de idiomas** con corpus como MASSIVE [23], y evaluación de aumentación de datos [24] para las clases con frontera ambigua.

CÓDIGO IMPLEMENTADO

El código completo —generador del corpus, pipeline de experimentos y tres notebooks reproducibles (construcción del corpus, modelos clásicos y sistema híbrido)— se entrega como anexo del proyecto. La estructura es: `corpus/generar_corpus.py`, `experimentos.py` y `notebooks/{01_corpus, 02_modelos_clasicos, 03_hibrido}.ipynb`. Toda la generación es reproducible con semilla fija (`RANDOM_STATE=42`).

Repositorio: <https://github.com/Rodvdev/cs3061-intent-whatsapp>

REFERENCIAS

- [1] H. Chen, X. Liu, D. Yin, and J. Tang, "A survey on dialogue systems: Recent advances and new frontiers," *ACM SIGKDD Explorations Newsletter*, vol. 19, no. 2, pp. 25–35, 2017.
- [2] G. Tur and R. De Mori, *Spoken Language Understanding: Systems for Extracting Semantic Information from Speech*. Hoboken, NJ, USA: John Wiley & Sons, 2011.
- [3] S. Larson, A. Mahendran, J. J. Peper, C. Clarke *et al.*, "An evaluation dataset for intent classification and out-of-scope prediction," in *Proc. EMNLP-IJCNLP*, 2019, pp. 1311–1316.
- [4] A. Coucke, A. Saade, A. Ball, T. Bluche *et al.*, "Snips voice platform: An embedded spoken language understanding system for private-by-design voice interfaces," *arXiv preprint arXiv:1805.10190*, 2018.
- [5] T. B. Brown, B. Mann, N. Ryder, M. Subbiah *et al.*, "Language models are few-shot learners," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 1877–1901.
- [6] B. Pang and L. Lee, "Opinion mining and sentiment analysis," *Foundations and Trends in Information Retrieval*, vol. 2, no. 1–2, pp. 1–135, 2008.
- [7] T. Joachims, "Text categorization with support vector machines: Learning with many relevant features," in *Proc. 10th European Conf. on Machine Learning (ECML)*. Springer, 1998, pp. 137–142.
- [8] A. Joulin, E. Grave, P. Bojanowski, and T. Mikolov, "Bag of tricks for efficient text classification," in *Proc. 15th Conf. of the European Chapter of the ACL (EACL)*, Vol. 2, 2017, pp. 427–431.
- [9] X. Liu, A. Eshghi, P. Swietojanski, and V. Rieser, "Benchmarking natural language understanding services for building conversational agents," in *Proc. 10th Int. Workshop on Spoken Dialogue Systems (IWSDS)*, 2019, pp. 165–183.
- [10] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [11] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [12] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967.
- [13] I. Casanueva, T. Temčinas, D. Gerz, M. Henderson, and I. Vulić, "Efficient intent detection with dual sentence encoders," in *Proc. 2nd Workshop on NLP for Conversational AI (NLP4ConvAI)*, 2020, pp. 38–45.
- [14] J.-G. Zhang, K. Hashimoto, W. Liu *et al.*, "Discriminative nearest neighbor few-shot intent detection by transferring natural language inference," in *Proc. EMNLP*, 2020, pp. 5064–5082.
- [15] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," *arXiv preprint arXiv:1301.3781*, 2013.
- [16] J. Pennington, R. Socher, and C. D. Manning, "GloVe: Global vectors for word representation," in *Proc. EMNLP*, 2014, pp. 1532–1543.
- [17] A. Vaswani, N. Shazeer, N. Parmar *et al.*, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [18] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. NAACL-HLT*, 2019, pp. 4171–4186.
- [19] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," in *Proc. EMNLP-IJCNLP*, 2019, pp. 3982–3992.
- [20] L. Ouyang, J. Wu, X. Jiang *et al.*, "Training language models to follow instructions with human feedback," in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 27 730–27 744.
- [21] A. Conneau, K. Khandelwal, N. Goyal *et al.*, "Unsupervised cross-lingual representation learning at scale," in *Proc. 58th Annual Meeting of the ACL*, 2020, pp. 8440–8451.
- [22] S. Schuster, S. Gupta, R. Shah, and M. Lewis, "Cross-lingual transfer learning for multilingual task oriented dialog," in *Proc. NAACL-HLT*, 2019, pp. 3795–3805.
- [23] J. FitzGerald, C. Hench, C. Peris *et al.*, "MASSIVE: A 1M-example multilingual natural language understanding dataset with 51 typologically diverse languages," in *Proc. 61st Annual Meeting of the ACL*, 2023, pp. 4277–4302.
- [24] J. Wei and K. Zou, "EDA: Easy data augmentation techniques for boosting performance on text classification tasks," in *Proc. EMNLP-IJCNLP*, 2019, pp. 6382–6388.
- [25] F. Pedregosa, G. Varoquaux, A. Gramfort *et al.*, "Scikit-learn: Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.